

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN 1



BÁO CÁO MÔN HỌC
PHÁT TRIỂN CÁC HỆ THỐNG THÔNG MINH
ASSIGNMENT 05

Họ tên:	Phan Văn Khôi
Mã sinh viên:	B23DCCN447
Lớp:	D23CTPM01-B
Giảng viên	PGS. TS. Trần Đình Quế

Hà Nội – 2026

Contents

Thông Tin Project	1
1 Cơ Sở Lý Thuyết Về CNN Dưới Dạng Hàm Hợp	2
1.1 CNN như một chuỗi hàm	2
1.2 Convolution, BatchNorm, ReLU và Pooling	2
1.3 Classifier và xác suất đầu ra	2
1.4 Backpropagation và tối ưu	3
2 Các Kiến Trúc Phát Triển Từ CNN	4
2.1 Basic CNN	4
2.2 Compact VGG	4
2.3 Compact ResNet	4
2.4 Compact DenseNet	4
3 Thiết Kế Thực Nghiệm Và Benchmark	6
3.1 Dataset và nhiệm vụ	6
3.2 Tiền xử lý và chống data leakage	6
3.3 Cấu hình huấn luyện	6
3.4 Metric đánh giá	7
4 Thực Nghiệm Trên Diabetes	8
4.1 Đặc điểm dữ liệu	8
4.2 Tiền xử lý và mô hình	8
4.3 Diễn biến huấn luyện	8
4.4 Kết quả benchmark	9
4.5 Ma trận nhầm lẫn và phân tích lỗi	9
5 Thực Nghiệm Trên Fashion-MNIST	10
5.1 Khảo sát dữ liệu	10
5.2 Tiền xử lý và cấu hình	10
5.3 Diễn biến huấn luyện	11
5.4 Kết quả benchmark	11
5.5 Ma trận nhầm lẫn và phân tích lỗi	12
6 Thực Nghiệm Trên CIFAR-100	14
6.1 Khảo sát dữ liệu	14
6.2 Tiền xử lý và cấu hình	15
6.3 Diễn biến huấn luyện	16
6.4 Kết quả benchmark	16

6.5	Ma trận nhầm lẫn và phân tích lỗi	17
7	Tổng Hợp Đối Chuẩn Và Kết Luận	19
7.1	Tổng hợp kết quả chính	19
7.2	So sánh theo độ khó dữ liệu	19
7.3	Công bằng và giới hạn của benchmark	19
7.4	Kiểm toán khả năng tái lập	20
7.5	Kết luận	20

List of Figures

4.1	Learning curves của bốn mô hình trên Diabetes	8
4.2	So sánh metric test của bốn mô hình trên Diabetes	9
4.3	Ma trận nhầm lẫn chuẩn hóa của bốn mô hình trên Diabetes	9
5.1	Ảnh mẫu của 10 lớp Fashion-MNIST	10
5.2	Learning curves của bốn mô hình trên Fashion-MNIST	11
5.3	So sánh metric test của bốn mô hình trên Fashion-MNIST	11
5.4	Ma trận nhầm lẫn chuẩn hóa của bốn mô hình trên Fashion-MNIST	12
5.5	Một số dự đoán sai của mô hình tốt nhất trên Fashion-MNIST	13
6.1	Ảnh mẫu của một số lớp đầu tiên trong CIFAR-100	15
6.2	Learning curves của bốn mô hình trên CIFAR-100	16
6.3	So sánh metric test của bốn mô hình trên CIFAR-100	16
6.4	Ma trận nhầm lẫn chuẩn hóa của bốn mô hình trên CIFAR-100	17
6.5	Một số dự đoán sai của mô hình tốt nhất trên CIFAR-100	18

List of Tables

2.1	Bốn kiến trúc benchmark trong Assignment 05	5
3.1	Tổng quan dữ liệu Assignment 05	6
3.2	Cấu hình huấn luyện theo dataset	7
4.1	Benchmark bốn mô hình Conv1D trên Diabetes	9
5.1	Benchmark bốn mô hình Conv2D trên Fashion-MNIST	11
6.1	Benchmark bốn mô hình Conv2D trên CIFAR-100	16
7.1	Mô hình tốt nhất theo metric chính của từng dataset	19
7.2	Checklist tái lập Assignment 05	20

Thông Tin Project

GitHub project: <https://github.com/KhoiF/PTHTTM>

Báo cáo này tổng hợp kết quả từ ba notebook của Assignment 05:

- Diabetes: `src/Assignment 05/diabets/notebook/diabetes_cnn_benchmark.ipynb`;
- Fashion-MNIST: `src/Assignment 05/Fashion-MNIST/notebook/fashion_mnist_cnn_benchmark.ipynb`;
- CIFAR-100: `src/Assignment 05/CIFAR-100/notebook/cifar100_cnn_benchmark.ipynb`.

Mỗi notebook tự chứa lý thuyết, minh họa hàm hợp của CNN, pipeline dữ liệu, huấn luyện bốn kiến trúc và đánh giá kết quả trên test set. Các hình trong báo cáo được trích từ output đã lưu của chính notebook và đặt tại `Report/Assignment 05/images/generated`.

Cơ Sở Lý Thuyết Về CNN Dưới Dạng Hàm Hợp

1.1 CNN như một chuỗi hàm

Một mạng nơ-ron tích chập có thể được nhìn như một hàm hợp nhiều phép biến đổi:

$$\mathbf{x} \rightarrow \text{Conv} \rightarrow \text{BatchNorm} \rightarrow \text{ReLU} \rightarrow \text{Pooling} \rightarrow \text{Classifier} \rightarrow \hat{\mathbf{y}}. \quad (1.1)$$

Trong đó $\mathbf{x}$ là đầu vào, $\hat{\mathbf{y}}$ là xác suất dự đoán. Với bài toán ảnh, $\mathbf{x}$ là tensor $H \times W \times C$. Với Diabetes, vector 15 đặc trưng được reshape thành chuỗi (15, 1) để minh họa Conv1D. Cách dùng Conv1D trên dữ liệu bảng chủ yếu phục vụ mục tiêu học kiến trúc, vì thứ tự cột không có quan hệ lân cận tự nhiên như pixel.

1.2 Convolution, BatchNorm, ReLU và Pooling

Với ảnh, phép convolution tạo feature map bằng cách trượt kernel trên vùng cục bộ:

$$Y_{i,j,k} = b_k + \sum_{u=0}^{K_h-1} \sum_{v=0}^{K_w-1} \sum_{c=0}^{C-1} X_{i+u,j+v,c} W_{u,v,c,k}. \quad (1.2)$$

Kernel dùng chung trọng số tại nhiều vị trí, vì vậy CNN học được mẫu cục bộ với số tham số ít hơn fully connected.

Batch Normalization chuẩn hóa activation theo batch rồi học lại hệ số scale và shift:

$$\text{BN}(z) = \gamma \frac{z - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}} + \beta. \quad (1.3)$$

ReLU thêm phi tuyến:

$$\text{ReLU}(z) = \max(0, z). \quad (1.4)$$

Pooling giảm kích thước không gian và giúp feature ổn định hơn trước dịch chuyển nhỏ. Trong các notebook, ảnh dùng Conv2D, còn Diabetes dùng Conv1D.

1.3 Classifier và xác suất đầu ra

Sau các block convolution, Global Average Pooling gom feature map thành vector đặc trưng. Với phân loại đa lớp, softmax biến logits thành phân phối xác suất:

$$\hat{y}_k = \frac{\exp(z_k)}{\sum_{j=1}^K \exp(z_j)}. \quad (1.5)$$

Fashion-MNIST và CIFAR-100 dùng softmax với lần lượt 10 và 100 lớp. Với Diabetes, đầu ra là một xác suất nhị phân:

$$\hat{y} = \sigma(z) = \frac{1}{1 + \exp(-z)}. \quad (1.6)$$

Notebook chọn threshold tối ưu F1 trên validation, sau đó khóa threshold để đánh giá test.

1.4 Backpropagation và tối ưu

Gradient trong CNN lan truyền ngược qua classifier, pooling, activation, BatchNorm và convolution. Trong convolution, cùng một kernel được dùng tại nhiều vị trí nên gradient trọng số là tổng đóng góp từ mọi cửa sổ. Các mô hình trong Assignment 05 dùng TensorFlow/Keras và automatic differentiation. Optimizer chung là AdamW:

$$\theta_{t+1} = \theta_t - \eta (\hat{g}_t + \lambda \theta_t), \quad (1.7)$$

trong đó λ là weight decay. Learning rate được giảm bằng ReduceLROnPlateau và checkpoint tốt nhất được khôi phục bằng early stopping theo validation loss.

Các Kiến Trúc Phát Triển Từ CNN

2.1 Basic CNN

Basic CNN trong ba notebook dùng các block tuần tự:

$$\text{Block}(\mathbf{x}) = \text{Pool}(\text{ReLU}(\text{BN}(\text{Conv}(\mathbf{x})))) . \quad (2.1)$$

Sau các stage convolution, mô hình dùng Global Average Pooling và classifier. Kiến trúc này là baseline trực tiếp để so sánh với VGG, ResNet và DenseNet.

2.2 Compact VGG

VGG tăng độ sâu bằng cách chồng nhiều convolution kernel 3×3 . Một stage có thể viết:

$$\mathbf{x}_{s+1} = \text{Pool}(H_{s,m} \circ H_{s,m-1} \circ \dots \circ H_{s,1}(\mathbf{x}_s)) , \quad (2.2)$$

với H là Conv-BN-ReLU. Assignment 05 dùng số convolution theo stage là $[2, 2, 3]$ và số filter $[32, 64, 128]$.

2.3 Compact ResNet

ResNet học phân dư thay vì toàn bộ ánh xạ. Một residual block có dạng:

$$\mathbf{y} = \text{ReLU}(F(\mathbf{x}) + P(\mathbf{x})) , \quad (2.3)$$

trong đó F là nhánh hai convolution và P là shortcut. Khi số channel hoặc stride thay đổi, P dùng convolution 1×1 để chiếu về cùng shape. Notebook dùng stem 32 filter, ba stage $[32, 64, 128]$ và hai residual block mỗi stage.

2.4 Compact DenseNet

DenseNet tái sử dụng feature bằng cách nối output của các lớp trước:

$$\mathbf{x}_l = H_l([\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_{l-1}]) . \quad (2.4)$$

Mỗi dense layer thêm g feature map mới, với g gọi là growth rate. Assignment 05 dùng ba dense block $[3, 4, 4]$, growth rate 16 và transition block nén số kênh theo hệ số 0.5.

Table 2.1: Bốn kiến trúc benchmark trong Assignment 05

Mô hình	Ý tưởng chính	Cấu hình compact	Vai trò
Basic CNN	Conv-BN-ReLU-Pool theo chuỗi	Stage $32 \rightarrow 64 \rightarrow 128$	Baseline trực tiếp
Compact VGG	Chồng nhiều convolution 3×3	Conv count [2, 2, 3]	Kiểm tra lợi ích tăng depth tuần tự
Compact ResNet	Residual connection	3 stage, 2 residual block mỗi stage	Cải thiện luồng gradient
Compact DenseNet	Concatenate feature trước đó	Dense block [3, 4, 4], growth 16	Tái sử dụng feature, ít tham số hơn ResNet

Thiết Kế Thực Nghiệm Và Benchmark

3.1 Dataset và nhiệm vụ

Ba dataset đại diện cho ba dạng bài toán khác nhau:

- **Diabetes**: phân loại nhị phân trên dữ liệu bảng, dùng Conv1D để minh họa kiến trúc.
- **Fashion-MNIST**: phân loại ảnh xám 28×28 với 10 lớp quần áo.
- **CIFAR-100**: phân loại ảnh màu 32×32 với 100 lớp fine-grained.

Table 3.1: Tổng quan dữ liệu Assignment 05

Dataset	Dữ liệu gốc	Train	Validation	Test	Số lớp
Diabetes	100,000 dòng, loại 3,854 dòng trùng	67,302	14,422	14,422	2
Fashion-MNIST	60,000 train, 10,000 test	54,000	6,000	10,000	10
CIFAR-100	50,000 train, 10,000 test	45,000	5,000	10,000	100

3.2 Tiền xử lý và chống data leakage

Tất cả split train/validation/test đều dùng stratified split với seed 42. Test set không tham gia fit preprocessing, early stopping hoặc chọn threshold.

Với Diabetes, sáu biến số được chuẩn hóa bằng StandardScaler fit trên train. Hai biến phân loại gender và smoking_history được one-hot thành 9 cột, tạo vector 15 đặc trưng. Vector này được reshape thành (15, 1) cho Conv1D. Do lớp dương chỉ chiếm khoảng 8.5%, notebook dùng class weight và threshold tối ưu F1 trên validation.

Với Fashion-MNIST và CIFAR-100, ảnh được rescale về $[0, 1]$ rồi chuẩn hóa bằng mean/std học từ train. Augmentation chỉ áp dụng trong training: horizontal flip, translation, rotation, zoom và contrast nhẹ với CIFAR-100. Validation và test giữ nguyên để đo khả năng tổng quát hóa.

3.3 Cấu hình huấn luyện

Các mô hình trong cùng dataset dùng chung split, loss, optimizer, augmentation và callback. AdamW có learning rate 10^{-3} và weight decay 10^{-4} . ReduceLROnPlateau dùng factor 0.5,

patience 2 và min learning rate 10^{-5} . Early stopping theo validation loss và khôi phục best weights.

Table 3.2: Cấu hình huấn luyện theo dataset

Dataset	Epoch tối đa	Batch	Early stopping patience	Loss
Diabetes	30	256	5	Binary cross-entropy
Fashion-MNIST	25	128	5	Sparse categorical cross-entropy
CIFAR-100	20	64	8	Sparse categorical cross-entropy

3.4 Metric đánh giá

Với ảnh, báo cáo dùng Accuracy, Macro Precision, Macro Recall, Macro F1, test loss, số tham số, best epoch, thời gian train và inference. Macro metric quan trọng vì nó cho mỗi lớp trọng số ngang nhau.

Với Diabetes, báo cáo dùng Accuracy, Balanced Accuracy, Precision, Recall/Sensitivity, Specificity, F1, ROC-AUC, PR-AUC và threshold. Do dữ liệu mất cân bằng, F1, PR-AUC và balanced accuracy có ý nghĩa hơn accuracy thuần.

Thực Nghiệm Trên Diabetes

4.1 Đặc điểm dữ liệu

Dataset Diabetes có 100,000 dòng ban đầu. Notebook xác nhận có đúng 3,854 dòng trùng và loại trước khi split, còn 96,146 dòng. Nhân dương chỉ khoảng 8.5%, vì vậy mô hình để đạt accuracy cao nếu thiên về lớp âm. Điều này khiến recall, specificity, F1 và PR-AUC trở thành nhóm metric chính.

4.2 Tiền xử lý và mô hình

Sáu biến số gồm tuổi, hypertension, heart disease, BMI, HbA1c và blood glucose được chuẩn hóa theo train. Hai biến phân loại được one-hot, tạo vector 15 chiều rồi reshape thành (15, 1). Bốn kiến trúc Conv1D có cùng tinh thần như bản ảnh: Basic CNN, Compact VGG, Compact ResNet và Compact DenseNet. Mỗi mô hình chọn threshold tối ưu F1 trên validation trước khi đánh giá test.

4.3 Diễn biến huấn luyện




Figure 4.1: Learning curves của bốn mô hình trên Diabetes

Các mô hình đều hội tụ trong giới hạn 30 epoch. Basic CNN chạy nhanh nhất nhưng có F1 thấp hơn nhóm kiến trúc sâu. Compact DenseNet và Compact ResNet cho PR-AUC gần tương đương, cho thấy các kết nối tắt hoặc nối feature đều hữu ích khi mô hình sâu hơn baseline.

4.4 Kết quả benchmark

Table 4.1: Benchmark bốn mô hình Conv1D trên Diabetes

Mô hình	Acc	Bal Acc	Precision	Recall	Spec	F1	ROC-AUC	PR-AUC	Threshold	Params
Compact ResNet	0.9694	0.8575	0.9125	0.7217	0.9933	0.8060	0.9766	0.8840	0.865	242,273
Compact DenseNet	0.9686	0.8635	0.8889	0.7358	0.9911	0.8052	0.9767	0.8841	0.830	94,629
Compact VGG	0.9685	0.8570	0.9009	0.7217	0.9923	0.8014	0.9769	0.8804	0.815	159,265
Basic CNN	0.9651	0.8630	0.8453	0.7390	0.9869	0.7886	0.9766	0.8793	0.755	40,033




Figure 4.2: So sánh metric test của bốn mô hình trên Diabetes

4.5 Ma trận nhầm lẫn và phân tích lỗi




Figure 4.3: Ma trận nhầm lẫn chuẩn hóa của bốn mô hình trên Diabetes

Compact ResNet đạt F1 cao nhất 0.8060 với threshold 0.865. Compact DenseNet đạt balanced accuracy và PR-AUC cao nhất rất sát ResNet. Basic CNN có recall cao nhất nhưng specificity và precision thấp hơn, nghĩa là mô hình bắt được nhiều ca dương hơn nhưng tạo nhiều false positive hơn. Với ứng dụng y tế, lựa chọn threshold cần phụ thuộc chi phí bỏ sót bệnh so với chi phí cảnh báo sai.

Thực Nghiệm Trên Fashion-MNIST

5.1 Khảo sát dữ liệu

Fashion-MNIST gồm 60,000 ảnh train và 10,000 ảnh test, kích thước $28 \times 28 \times 1$. Notebook tách 54,000 ảnh train và 6,000 ảnh validation bằng stratified split. Các lớp gồm áo, quần, giày, túi và các nhóm trang phục có hình dạng gần nhau.




Figure 5.1: Ảnh mẫu của 10 lớp Fashion-MNIST

5.2 Tiền xử lý và cấu hình

Ảnh được rescale về $[0, 1]$ và chuẩn hóa bằng mean/std train. Augmentation gồm horizontal flip, translation, rotation nhẹ và zoom. Bốn kiến trúc Conv2D huấn luyện từ đầu, không dùng pretrained. Tập test 10,000 ảnh chỉ được dùng sau khi đã chọn best weights bằng validation loss.

5.3 Diễn biến huấn luyện




Figure 5.2: Learning curves của bốn mô hình trên Fashion-MNIST

Fashion-MNIST cân bằng giữa các lớp nên Accuracy và Macro F1 gần nhau. Basic CNN học được baseline tốt nhưng kém nhóm mô hình sâu. VGG cải thiện nhờ nhiều convolution 3×3 . ResNet đạt kết quả tốt nhất, cho thấy residual connection giúp mô hình sâu hơn ổn định trong cấu hình compact.

5.4 Kết quả benchmark

Table 5.1: Benchmark bốn mô hình Conv2D trên Fashion-MNIST

Mô hình	Accuracy	Macro-P	Macro-R	Macro-F1	Loss	Params	Epoch tốt	Train(s)	Infer(s)
Compact ResNet	0.9204	0.9201	0.9204	0.9199	0.2203	698,282	23	2,114.66	3.92
Compact VGG	0.9173	0.9190	0.9173	0.9178	0.2204	453,546	23	1,047.41	1.92
Compact DenseNet	0.9032	0.9031	0.9032	0.9030	0.2571	163,458	25	3,043.95	4.56
Basic CNN	0.8743	0.8766	0.8743	0.8746	0.3453	111,146	23	368.83	0.67




Figure 5.3: So sánh metric test của bốn mô hình trên Fashion-MNIST

5.5 Ma trận nhầm lẫn và phân tích lỗi




Figure 5.4: Ma trận nhầm lẫn chuẩn hóa của bốn mô hình trên Fashion-MNIST

Compact ResNet đạt Macro F1 cao nhất 0.9199 và accuracy 0.9204. Compact VGG đứng rất gần với Macro F1 0.9178, trong khi DenseNet thấp hơn dù có ít tham số hơn VGG và ResNet. Những nhầm lẫn phổ biến thường xuất hiện giữa shirt, pullover và coat vì các lớp này có silhouette tương tự ở ảnh xám độ phân giải thấp.




Figure 5.5: Một số dự đoán sai của mô hình tốt nhất trên Fashion-MNIST

Thực Nghiệm Trên CIFAR-100

6.1 Khảo sát dữ liệu

CIFAR-100 gồm 50,000 ảnh train và 10,000 ảnh test, ảnh màu $32 \times 32 \times 3$. Bộ dữ liệu có 100 lớp fine-grained, mỗi lớp có 500 ảnh train gốc và 100 ảnh test. Notebook tách 45,000 ảnh train và 5,000 ảnh validation bằng stratified split.




Figure 6.1: Ảnh mẫu của một số lớp đầu tiên trong CIFAR-100

6.2 Tiền xử lý và cấu hình

Archive `cifar-100-python.tar.gz` được tải từ nguồn chính thức và kiểm tra MD5. Notebook đọc các file pickle `train`, `test` và `meta`. Ảnh được reshape về $(N, 32, 32, 3)$. Augmentation gồm horizontal flip, translation, rotation, zoom và contrast nhẹ. Do số lớp lên tới 100, bài toán khó hơn đáng kể so với Fashion-MNIST.

6.3 Diễn biến huấn luyện




Figure 6.2: Learning curves của bốn mô hình trên CIFAR-100

Trong giới hạn 20 epoch, tất cả mô hình đều có best epoch bằng 20. Điều này cho thấy mô hình vẫn còn khả năng cải thiện nếu tăng số epoch hoặc dùng lịch learning rate dài hơn. Dù vậy, benchmark vẫn đủ để so sánh xu hướng: ResNet tốt nhất, VGG đứng thứ hai, DenseNet và Basic CNN thấp hơn.

6.4 Kết quả benchmark

Table 6.1: Benchmark bốn mô hình Conv2D trên CIFAR-100

Mô hình	Accuracy	Macro-P	Macro-R	Macro-F1	Loss	Params	Epoch tốt	Train(s)	Infer(s)
Compact ResNet	0.5062	0.5665	0.5062	0.5055	1.8785	710,468	20	2,018.57	6.70
Compact VGG	0.4501	0.5011	0.4501	0.4447	2.1184	465,732	20	988.18	2.58
Compact DenseNet	0.3796	0.4288	0.3796	0.3719	2.3846	174,564	20	2,841.07	6.74
Basic CNN	0.3156	0.3639	0.3156	0.3035	2.7271	123,332	20	373.66	0.97




Figure 6.3: So sánh metric test của bốn mô hình trên CIFAR-100

6.5 Ma trận nhầm lẫn và phân tích lỗi




Figure 6.4: Ma trận nhầm lẫn chuẩn hóa của bốn mô hình trên CIFAR-100

Compact ResNet đạt Macro F1 0.5055 và accuracy 0.5062, cao nhất trong bốn mô hình. Khoảng cách giữa ResNet và Basic CNN hơn 20 điểm phần trăm accuracy, cho thấy dữ liệu nhiều lớp cần kiến trúc có khả năng truyền gradient tốt. Tuy nhiên, CIFAR-100 vẫn còn khó trong cấu hình compact 20 epoch; nhiều lớp có hình dạng hoặc ngữ nghĩa gần nhau dễ bị nhầm.




Figure 6.5: Một số dự đoán sai của mô hình tốt nhất trên CIFAR-100

Tổng Hợp Đối Chuẩn Và Kết Luận

7.1 Tổng hợp kết quả chính

Table 7.1: Mô hình tốt nhất theo metric chính của từng dataset

Dataset	Mô hình tốt nhất	Metric chính	Score	Accuracy	Params	Train(s)
Diabetes	Compact ResNet	F1	0.8060	0.9694	242,273	78.77
Fashion-MNIST	Compact ResNet	Macro-F1	0.9199	0.9204	698,282	2,114.66
CIFAR-100	Compact ResNet	Macro-F1	0.5055	0.5062	710,468	2,018.57

Trong cả ba dataset, Compact ResNet là mô hình có metric chính cao nhất. Kết quả này phù hợp với trực giác lý thuyết: residual connection giúp mô hình sâu hơn vẫn tối ưu ổn định. VGG cũng mạnh trên ảnh, đặc biệt Fashion-MNIST, nhưng thiếu shortcut nên khó vượt ResNet trong cùng số epoch. DenseNet có số tham số thấp hơn ResNet ở cả ba dataset, nhưng trong các lần chạy này chưa đạt score cao nhất.

7.2 So sánh theo độ khó dữ liệu

Diabetes có accuracy cao vì lớp âm chiếm đa số, nhưng F1 chỉ quanh 0.80 do bài toán mất cân bằng. Fashion-MNIST cân bằng và có 10 lớp, ảnh đơn giản hơn CIFAR-100 nên Compact ResNet đạt Macro F1 0.9199. CIFAR-100 có 100 lớp và chỉ 500 ảnh train gốc mỗi lớp, vì vậy Macro F1 0.5055 trong 20 epoch phản ánh độ khó fine-grained classification.

7.3 Công bằng và giới hạn của benchmark

Benchmark giữ cùng split, preprocessing, optimizer và callback trong từng dataset. Tuy nhiên, thời gian train phụ thuộc trạng thái máy và backend TensorFlow tại thời điểm chạy. Số epoch CIFAR-100 bị giới hạn ở 20 để phù hợp thời gian CPU, nên kết quả chưa đại diện cho khả năng tối đa của từng kiến trúc. Ngoài ra, Conv1D trên Diabetes chỉ là minh họa kiến trúc CNN trên dữ liệu bảng; để tối ưu bài toán thực tế cần so sánh thêm với mô hình chuyên cho tabular.

7.4 Kiểm toán khả năng tái lập

Table 7.2: Checklist tái lập Assignment 05

Hạng mục	Cách thực hiện	Ý nghĩa
Random seed	Seed 42 cho NumPy, Python và TensorFlow	Giảm dao động split và khởi tạo
Split dữ liệu	Stratified train/validation/test	Giữ phân phối lớp ổn định
Preprocessing	Fit scaler hoặc mean/std chỉ trên train	Chống data leakage
Augmentation	Chỉ hoạt động trong training	Validation/test phản ánh dữ liệu gốc
Callback	ReduceLROnPlateau và EarlyStopping	Ổn định huấn luyện
Threshold Diabetes	Chọn trên validation, khóa khi test	Không chọn threshold từ test
Metric	Accuracy, macro metric, F1, AUC và thời gian	So sánh chất lượng và chi phí

7.5 Kết luận

Báo cáo đã xây dựng và đối chuẩn bốn kiến trúc CNN compact trên ba dataset của Assignment 05. Các kết luận chính gồm:

1. CNN có thể được hiểu thống nhất dưới dạng hàm hợp từ convolution, BatchNorm, ReLU, pooling đến classifier.
2. VGG tăng năng lực biểu diễn bằng cách chồng nhiều convolution 3×3 .
3. ResNet đạt kết quả tốt nhất trên cả Diabetes, Fashion-MNIST và CIFAR-100 nhờ residual connection.
4. DenseNet có lợi thế tái sử dụng feature và số tham số thấp hơn ResNet, nhưng chưa thắng trong các cấu hình compact đã chạy.
5. Độ khó dữ liệu tăng rõ từ Fashion-MNIST sang CIFAR-100, thể hiện qua Macro F1 giảm từ 0.9199 xuống 0.5055.

Hướng mở rộng gồm chạy nhiều seed để báo cáo độ ổn định, tăng epoch cho CIFAR-100, thử lịch cosine decay, mixup/cutout và so sánh thêm với mô hình tabular chuyên dụng cho Diabetes.